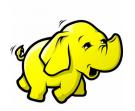
Cloudera Administrator Apache Hadoop

Parte 02-2 Comandos do HDFS



Marco Reis http://marcoreis.net

Agenda

- Comandos HDFS
 - fsck
 - getconf
 - balancer
 - dfsadmin
 - namenode
- Operações no sistema de arquivos
 - Alterar e mostrar
 - Criar, excluir, copiar e mover
 - Mostrar informações
 - Replicação
- Performance do disco

Comandos de administração



- Os comandos HDFS são executados através do programa <u>hdfs</u>
- Rodar o script sem parâmetros mostra a lista de comandos disponíveis
- Não confundir o usuário <u>hdfs</u> com o programa <u>hdfs</u>
- Os comandos de administração do HDFS devem ser executados pelo usuário hdfs, que é chamado de superuser
 - Apenas quando a segurança do cluster está ativada

O programa hdfs

- Os comandos são executados com o usuário <u>hdfs</u>
 - \$ su hdfs
- Depois, vamos rodar o programa <u>hdfs</u>
 - \$ hdfs
- Pode ser usado em qualquer computador do cluster ou no cliente

```
dfs@hadoopclient:~$ hdfs
sage: hdfs [--config confdir] COMMAND
     where COMMAND is one of:
                     run a filesystem command on the file systems supported in Hadoop
                     format the DFS filesystem
namenode -format
secondarynamenode
                     run the DFS secondary namenode
                     run the DFS namenode
namenode
iournalnode
                     run the DFS journalnode
zkfc
                     run the ZK Failover Controller daemon
datanode
                     run a DFS datanode
dfsadmin
                     run a DFS admin client
diskbalancer
                     Distributes data evenly among disks on a given node
                     run a DFS HA admin client
haadmin
                     run a DFS filesystem checking utility
fsck
balancer
                     run a cluster balancing utility
                     get JMX exported values from NameNode or DataNode.
                     run a utility to move block replicas across
                     storage types
                     apply the offline fsimage viewer to an fsimage
                     apply the offline fsimage viewer to an legacy fsimage
oiv legacy
                     apply the offline edits viewer to an edits file
                     fetch a delegation token from the NameNode
fetchdt
                     get config values from configuration
                     get the groups which users belong to
groups
                     diff two snapshots of a directory or diff the
                     current directory contents with a snapshot
lsSnapshottableDir
                     list all snapshottable dirs owned by the current user
                                               Use -help to see options
portmap
                     run a portmap service
                      run an NFS version 3 gateway
                     configure the HDFS cache
cacheadmin
                     configure HDFS encryption zones
crypto
storagepolicies
                     list/get/set block storage policies
                     print the version
```

fsck



- Utilitário para checagem do sistema de arquivos
 - hdfs fsck <caminho> [parâmetro]

Parâmetros

- hdfs fsck /user -list-corruptfileblocks: mostra a lista dos blocos corrompidos
- hdfs fsck /user -delete: remove arquivos corrompidos
- hdfs fsck /user -move: move os arquivos corrompidos para o diretório /lost+found
- hdfs fsck /user -files: mostra os arquivos verificados
- hdfs fsck /user -files -blocks: mostra os caminhos dos arquivos e seus blocos
- hdfs fsck /user -files -blocks -locations: mostra a localização de cada bloco
- hdfs fsck /user -files -blocks -racks: topologia dos blocos datanodes

getconf



- Mostra as informações de configuração
 - \$ hdfs getconf <parametro>
- Parâmetros
 - hdfs getconf -namenodes
 - hdfs getconf -secondaryNameNodes
 - hdfs getconf -nnRpcAddresses
 - hdfs getconf -confKey [propriedade] (continua...)

getconf (continuação)



- As configurações estão disponíveis em http://headnode.lab:8088/conf
- Algumas delas:
 - dfs.datanode.address
 - dfs.namenode.name.dir
 - dfs.datanode.data.dir
 - dfs.replication
 - dfs.blocksize
 - dfs.heartbeat.interval
- Exemplo:
 - \$ hdfs getconf -confKey dfs.heartbeat.interval
 - \$ hdfs getconf -confKey dfs.datanode.address

Utilitário balancer



- Utilitário de balanceamento do cluster
- Com a adição de novos nós e a própria operação diária do cluster, podem acontecer desbalanceamentos
- O objetivo é que os discos do cluster tenham aproximadamente a mesma utilização
- Exemplo:
 - \$ hdfs balancer: para balancear os datanodes
 - \$ hdfs balancer -threshold 5: os datanodes podem ficar até 5% desbalanceados (padrão é 10%)

Utilitário dfsadmin

- Informações básicas do sistema de arquivos
- Para ver as opções:
 - \$ hdfs dfsadmin

```
lote: Administrative commands can only be run as the HDFS superuser.
       [-report [-live] [-dead] [-decommissioning]]
        -safemode <enter | leave | get | wait>]
        -saveNamespacel
        -rollEdits]
        -restoreFailedStorage true|false|check]
        -refreshNodes]
        -setQuota <quota> <dirname>...<dirname>]
        -clrOuota <dirname>...<dirname>l
        -setSpaceQuota <quota> <dirname>...<dirname>]
        -clrSpaceQuota <dirname>...<dirname>]
       [-finalizeUpgrade]
        -rollingUpgrade [<query|prepare|finalize>]]
        -refreshServiceAcl]
        -refreshUserToGroupsMappings]
        -refreshSuperUserGroupsConfiguration]
        -refreshCallQueue]
        -refresh <host:ipc port> <key> [arg1..argn]
        -reconfig <datanode|...> <host:ipc port> <start|status|properties>
        -printTopology]
        -deleteBlockPool datanode host:ipc port blockpoolId [force]]
        -setBalancerBandwidth <bandwidth in bytes per second>]
        -fetchImage <local directory>]
        -allowSnapshot <snapshotDir>]
        -disallowSnapshot <snapshotDir>]
        -shutdownDatanode <datanode host:ipc port> [upgrade]]
        -getDatanodeInfo <datanode host:ipc port>]
        -metasave filename]
        -triggerBlockReport [-incremental] <datanode host:ipc port>]
       [-listOpenFiles [-blockingDecommission] [-path <path>]]
       [-help [cmd]]
```

Utilitário dfsadmin



- Topologia do cluster
 - \$ hdfs dfsadmin -printTopology
- Modo de segurança
 - \$ hdfs dfsadmin -safemode enter|leave|get|wait
- Quotas
 - \$ hdfs dfsadmin -setQuota <limite> <diretório>: número limite para nomes de arquivos/diretórios
 - \$ hdfs dfsadmin -clrQuota <diretório>: arquivos e diretórios ilimitados
 - \$ hdfs dfsadmin -setSpaceQuota <espaço> <diretório>: total de espaço em disco usado pelos diretórios
 - + hdfs dfsadmin -clrSpaceQuota <diretório>: espaço ilimitado

Novo usuário no Linux



- Para os comandos a seguir use o seu usuário no Linux
- Crie um usuário no Linux igual ao criado no Hue:
 - \$ useradd -m dataengineer -s /bin/bash
- Para mudar a senha use o comando:
 - \$ passwd dataengineer
- Mude para o novo usuário use o comando:
 - \$ su dataengineer

Utilitário dfs

- O utilitário dfs apresenta comandos para manipulação de arquivos no HDFS
- Utiliza sintaxe parecida com o Linux/Unix, com o objetivo de aproveitar o conhecimento da equipe de operação
 - Exemplo: cat, du, df, cp, mkdir e mv
- Para listar as opções:
 - \$ hdfs dfs

```
| Indise| Indi
```

Operações no HDFS



- Copiar ou mover arquivos para o HDFS
- Crie um arquivo local chamado arquivoDeExemplo.txt
 - A parâmetro opcional -f força a sobrescrita do arquivo
 - + hdfs dfs -copyFromLocal arquivoDeExemplo.txt /user/dataengineer/
- Verificar se foi copiado
 - + hdfs dfs -ls /user/dataengineer/
- Para mover o arquivo use o comando:
 - + hdfs dfs -moveFromLocal arquivoDeExemplo.txt /user/dataengineer/
- Comando alternativo (faz a mesma coisa)
 - \$ hdfs dfs -put <-f> <arquivo-local> <diretorio-hdfs>

Utilitários do HDFS

- Cria um arquivo de tamanho 0
 - \$ hdfs dfs -touchz /user/dataengineer/testeAppend.txt
- Verifique o tamanho do arquivo
 - + hdfs dfs -ls /user/dataengineer/
- Anexa um ou vários arquivos locais em um arquivo do HDFS
 - \$ hdfs dfs -appendToFile arquivoDeExemplo.txt /user/dataengineer/testeAppend.txt

Mostrar conteúdo

cat

- Mostra o conteúdo de um arquivo no terminal
- \$ hdfs dfs -cat testeAppend.txt

tail

- Mostra os últimos 1000 bytes do arquivo
- \$ hdfs dfs -tail testeAppend.txt

text

- Mostra o conteúdo de um arquivo, incluindo outros formatos não texto
- \$ hdfs dfs -text testeAppend.txt

Observação:

- Para arquivos muito grandes deve-se usar o utilitário less
- \$ hdfs dfs -cat testeAppend.txt | less

Copiar para disco local

- Copia os dados de um diretório HDFS para o sistema de arquivos local
 - + hdfs dfs -copyToLocal <arquivo-no-hdfs> <diretorio-local>
 - \$ hdfs dfs -moveToLocal <arquivo-no-hdfs> <diretorio-local>
 - \$ hdfs dfs -get <arquivo-no-hdfs> <diretorio-local>

Copiar no HDFS

- Copia ou move os arquivos de um diretório HDFS para outro
 - + hdfs dfs -cp <-f> lista-de-arquivos-no-hdfs> <diretorio-destino-hdfs>
 - + hdfs dfs -mv <-f> lista-de-arquivos-no-hdfs> <diretorio-destino-hdfs>

Mostrar informações (count)

count

- Conta diretórios, arquivos e bytes
- Formato do resultado: DIR_COUNT, FILE_COUNT, CONTENT_SIZE, PATHNAME

Parâmetros

- q: mostra também os dados de quota (QUOTA, REMAINING_QUATA, SPACE_QUOTA, REMAINING_SPACE_QUOTA)
- h (human): mostra os dados em formato mais legível

Exemplo:

- \$ hdfs dfs -count <-q -v -h> <diretorio>

Mostrar informações (df / du)

- df
 - Mostra o espaço livre em disco
 - Aceita a opção -h
- Exemplo:
 - \$ hdfs dfs -df -h
- du
 - Mostra o espaço usado por arquivos e diretórios dentro de um diretório
 - A opção -s mostra o sumário
- Exemplo:
 - \$ hdfs dfs -du -s -h /user/dataengineer/

Encontrar arquivos

- find
 - Encontra arquivos através de uma expressão de busca
- Exemplo:
 - \$ hdfs dfs -find /user/ -name arquivoDeExemplo* -print
- Is
 - Lista o conteúdo do diretório
- Parâmetros
 - d: diretórios listados como arquivos
 - -h: formata os números
 - R: lista recursivamente os diretórios internos
- Exemplo:
 - \$ hdfs dfs -ls <diretorio>

Mostrar informações

stat

- Mostra estatísticas acerca do arquivo

Opções:

blocos (%b), tipo (%F), grupo (%g), nome (%n), tamanho do bloco (%o), replicação (%r), owner (%u) e data de modificação(%y, %Y).

Exemplo:

- \$ hdfs dfs -stat "%F %u:%g %b %y %n" <caminho-do-arquivo>

test

- Testa um caminho com base nesses parâmetros:
- d: retorna 0 se o caminho é um diretório
- -e: retorna 0 se o caminho existe
- -f: retorna 0 se o caminho é um arquivo
- -s: retorna 0 se o caminho não está vazio
- -z: retorna 0 seo arquivo tem tamanho 0

Exemplo:

- \$ hdfs dfs -test -[defsz] <caminho>

Excluir

- rm
 - Exclui um arquivo ou diretório
- Opções
 - -f: exclui e não mostra nenhum alerta
 - -R ou -r: exclui o diretório e seu conteúdo recursivamente (use com algum cuidado)
 - -skipTrash: exclui os dados imediatamente (evita a lixeira)
- Exemplo:
 - \$ hdfs dfs -rm [-f] [-r |-R] [-skipTrash] <caminho>
 - \$ hdfs dfs -rm /user/dataengineer/arquivoDeTeste.txt
 - \$ hdfs dfs -rm -r /user/dataengineer/diretorio
- expunge
 - Inicia o processo para esvaziar a lixeira (pode demorar um pouco)
- Exemplo
 - \$ hdfs dfs -expunge

Replicação

- Muda o fator de replicação de um arquivo/diretório
- A opção -w aguarda até que a operaçã termine
 - Não é indicada se existirem muitos arquivos no diretório
- Exemplos:
 - + hdfs dfs -setrep 2 /user/dataengineer/
 - \$ hdfs dfs -setrep -w 2 /user/dataengineer/
 - + hdfs dfs -du -h /user/dataengineer/

Performance com hdparm (opcional)

- hdparm
 - Utilitário para configuração e medição de performance do discl
- Instalação
 - \$ sudo apt-get install hdparm
- Exemplo:
 - \$ sudo hdparm -I /dev/sda
 - sudo hdparm -Tt /dev/sda
- Referência:
 - http://manpages.ubuntu.com/manpages/natty/man8/hdparm.8.html



Performance com dd (opcional)

- Mede a velocidade de gravação e leitura
- Velocidade de gravação (1GB de dados)
 - sudo dd if=/dev/zero of=/tmp/testfile bs=1G count=1
- Latência do disco (1000 gravações de 384k)
 - sudo dd if=/dev/zero of=/tmp/testfile bs=384k count=1k
- Referência:
 - https://www.thomas-krenn.com/en/wiki/Linux_I/O_Performance_Test s_using_dd

Dúvidas?

Marco Reis http://marcoreis.net